РУКОВОДСТВО ПОЛЬЗОВАТЕЛЯ

doc-analyzer

Версия

1.1

Содержание

1. Что такое doc-analyzer
2. Как запустить платформу
3. Основные понятия
4. Экраны интерфейса
5. Обзор
6. Результаты
7. Сканирование
8. Экспорт
9. Типичный сценарий работы
10. Что делать при ошибках
11. Часто задаваемые вопросы

---

1. Что такое doc-analyzer

doc-analyzer — это инструмент, который автоматически просматривает папки с файлами, изучает их содержимое с помощью искусственного интеллекта и даёт по каждому файлу чёткий ответ: что это, насколько важно и что с этим делать.

Платформа работает **полностью локально** на вашем компьютере. Ни один файл и ни одна строчка текста не покидает вашу машину — ИИ-модель запущена локально через Ollama.

Что платформа умеет

- Читать и анализировать **PDF, DOCX, PPTX, XLSX, XLS, TXT, MD, CSV, HTML**
- Распознавать текст на **фотографиях и сканах** (JPG, PNG, WEBP, TIFF)
- Извлекать текст из **изображений, вшитых в PDF** (схемы, сканы страниц)
- Присваивать каждому файлу **оценку ценности** от 0 до 100
- Давать **рекомендацию**: хранить, архивировать, проверить вручную или удалить
- Поддерживать **полнотекстовый поиск** по всем проанализированным файлам
- Экспортировать результаты в **CSV** для работы в Excel или другом инструменте

> **Важно**
> Платформа *не удаляет* файлы автоматически. Все рекомендации — только для вашего сведения.

---

2. Как запустить платформу

Для работы нужны два компонента: **Ollama** (локальный ИИ-сервер) и **doc-analyzer**.

Шаг 1 — Запустить Ollama

Ollama должен быть запущен в фоне перед стартом платформы. Обычно он запускается автоматически при входе в систему. Проверить можно, открыв в браузере:

```
http://localhost:11434
```

Если страница открылась — Ollama работает.

Шаг 2 — Создать виртуальное окружение

Откройте терминал, перейдите в папку проекта и выполните:

```
# Создать виртуальное окружение
python3 -m venv .venv

# Активировать — macOS / Linux
source .venv/bin/activate

# Активировать — Windows
.venv\Scripts\activate
```

После активации в начале строки терминала появится `(.venv)` — это значит, что окружение активно.

> **Важно**
> Виртуальное окружение нужно активировать каждый раз при открытии нового окна терминала перед запуском платформы.

Шаг 3 — Установить зависимости

Выполните один раз после создания окружения:

```
pip install -r requirements.txt
```

Установка занимает несколько минут. Повторно делать это не нужно — зависимости сохраняются в `.venv/`.

Шаг 4 — Запустить сервер платформы

```
python project/api.py
```

Браузер откроется автоматически на адресе `http://localhost:8000`.

> **Совет**
> Пока окно терминала открыто — платформа работает. Не закрывайте его во время сканирования.

3. Основные понятия

Оценка ценности (0–100)

Каждый файл получает числовую оценку. Чем выше — тем важнее содержимое:

Диапазон	Смысл	Типичные примеры
80–100	Критически важно	Договоры, удостоверения, финансовые документы, ключевые рабочие материалы
60–79	Полезно	Рабочие черновики, справочные материалы, важная переписка, протоколы встреч
30–59	Умеренная ценность	Общие заметки, информационный контент, вторичные материалы
0–29	Мало или нет ценности	Дубликаты, системные файлы, пустой контент, случайный мусор

Рекомендации

Рекомендация	Смысл
Хранить	Важный файл — держать в активном архиве под рукой
Архив	Файл не критичен, но может пригодиться — убрать в архив
На проверку	Неоднозначное содержимое — стоит просмотреть вручную
Мусор	Вероятно не нужен — но удалять автоматически не будет

Категории

- **Договор** — юридические документы, соглашения
- **Личное** — личные документы, фото, переписка
- **Рабочий материал** — рабочие файлы, проекты, задачи
- **Черновик** — незаконченные документы, наброски
- **Мусор** — файлы без смысловой ценности
- **Дубликат** — повторяющееся содержимое
- **Фото-документ** — фотография документа, скан
- **Фото-сцена** — обычная фотография (люди, место, событие)

Статусы обработки

Статус	Смысл
ok	Файл успешно проанализирован

pending	Файл в очереди на обработку или обрабатывается прямо сейчас
error	При обработке произошла ошибка (например, ИИ недоступен)

---

4. Экраны интерфейса

Навигация расположена в боковой панели слева. Всего четыре экрана.

1 Обзор

Главная страница с общей картиной по всей базе. Здесь отображается:

- **Четыре карточки статистики** — всего файлов в базе, успешно обработано, с ошибками, пропущено при последнем сканировании
- **Баннер активного сканирования** — появляется автоматически, когда идёт обработка файлов, и показывает прогресс в реальном времени
- **Распределение по рекомендациям** — сколько файлов получили каждую из четырёх рекомендаций
- **Распределение по категориям** — разбивка по типам содержимого
- **Последние обработанные** — 10 файлов, проанализированных последними

2 Результаты

Полная таблица всех проанализированных файлов с фильтрами, поиском и детальным просмотром.

Фильтры и сортировка

- **Рекомендация** — показать только файлы с нужным действием
- **Категория** — отфильтровать по типу содержимого
- **Тип файла** — pdf, jpg, docx и т.д.
- **Оценка от** — показать только файлы выше порога ценности
- **Сортировка** — по оценке, пути, дате обработки и другим полям
- **Строк на странице** — 25, 50 или 100

Поиск

Строка поиска выполняет **полнотекстовый поиск** — ищет не только по имени файла, но и по содержимому: сводкам, категориям и тексту документа. Введите ключевое слово и нажмите Enter.

Детальная панель

Нажмите на любую строку — справа выедет панель с подробной информацией:

- Полный путь, тип, размер, дата обработки
- Оценка ценности и рекомендация
- Краткое описание содержимого и объяснение оценки
- Список чанков (частей файла) с их оценками

- Кнопка **Изменить** — вручную скорректировать рекомендацию или категорию

3 Сканирование

Экран запуска нового анализа. Здесь настраивается что и как обрабатывать.

Форма запуска

- **Директория** — папка для сканирования. Можно ввести путь вручную или нажать кнопку выбора папки. Ниже отображается история недавних путей — кликните, чтобы выбрать повторно. Крестик удаляет путь из истории.
- **Обрабатывать изображения** — включить/выключить анализ standalone-фотографий (JPG, PNG и т.д.)
- **Изображения в PDF** — включить/выключить анализ картинок, вшитых в PDF-файлы
- **Выбор модели ИИ** — *Qwen3-VL 8B* (основная, точнее) или *Gemma 3 4B* (быстрее, для слабых компьютеров). При выборе Gemma 3 4B опции обработки изображений автоматически отключаются — эта модель работает только с текстом

Прогресс сканирования

После нажатия **Начать сканирование** отображается прогресс-бар, счётчики и имя текущего файла. Кнопка **Остановить** прерывает процесс. Уже обработанные файлы при повторном сканировании пропускаются мгновенно.

> **Сканирование долгих файлов**
> PDF с большим количеством вшитых изображений может занять значительное время — каждая картинка анализируется отдельно. Для ускорения отключите «Изображения в PDF», если детальный анализ картинок не нужен.

4 Экспорт

Экран выгрузки результатов в CSV-файл для работы в Excel, Google Sheets или других инструментах.

Фильтр экспорта

Выберите одну из карточек, чтобы экспортировать только нужные файлы: **Все результаты**, **Хранить**, **Архив**, **На проверку** или **Мусор**. На каждой карточке показано количество файлов в этой группе.

Что входит в CSV

Столбец	Содержимое
`path`	Полный путь к файлу
`ext`	Расширение файла
`size`	Размер в байтах
`value_score`	Оценка ценности (0–100)
`category`	Категория

`suggested_action`	Рекомендация
`summary`	Краткое описание содержимого
`why`	Обоснование оценки
`status`	Статус обработки (ok / error / pending)
`processed_at`	Дата и время обработки

История экспортов отображается ниже — можно повторно скачать любой из предыдущих файлов.

---

5. Типичный сценарий работы

1. Запустите платформу Активируйте виртуальное окружение (`source .venv/bin/activate`) и выполните `python project/api.py`. Браузер откроется автоматически.

2. Перейдите на экран «Сканирование» Выберите папку с файлами, настройте параметры и нажмите «Начать сканирование». Дождитесь завершения — прогресс виден в реальном времени.

3. Изучите результаты на экране «Обзор» Посмотрите общую картину: сколько файлов важных, сколько мусора, какие категории преобладают.

4. Разберите конкретные файлы в «Результатах» Отфильтруйте по рекомендации. Нажимайте на строки — читайте описание и обоснование. Если ИИ ошибся — скорректируйте рекомендацию кнопкой «Изменить».

5. Проверьте файлы «На проверку» Это файлы, в которых ИИ не был уверен. Они требуют вашего взгляда.

6. Экспортируйте нужные результаты На экране «Экспорт» выберите нужную группу и скачайте CSV для дальнейшей работы.

---

6. Что делать при ошибках

Часть файлов не обработалась (status = error)

Обычно происходит, если во время сканирования ИИ-сервер был перегружен или ноутбук ушёл в сон. Файлы с ошибками не теряются.

Решение: запустите сканирование той же папки повторно — файлы с ошибками будут обработаны заново, успешно обработанные ранее — пропущены.

Сканирование прервалось

Прогресс сохранён. При следующем запуске уже обработанные файлы будут пропущены, и сканирование продолжится с того места, где остановилось.

ИИ дал неверную оценку

Откройте файл в «Результатах», нажмите «Изменить» и скорректируйте рекомендацию и/или категорию вручную.

Статус Ollama — недоступен

Ollama не запущен или завис. Перезапустите его через системный трей или меню. После запуска обновите страницу.

---

7. Часто задаваемые вопросы

Где хранятся результаты анализа?

В локальной базе данных SQLite: `project/data/index.db`.

Можно ли добавить новые файлы после первого сканирования?

Да. Просто запустите сканирование той же или другой папки ещё раз. Уже обработанные файлы будут мгновенно пропущены — повторно анализируются только новые или изменённые файлы.

Что такое «чанки» в детальной панели?

Большие файлы разбиваются на смысловые части для анализа. Каждая часть оценивается отдельно. Итоговая оценка файла берётся из самой ценной части — той, что получила наибольший балл.

Что будет, если закрыть браузер во время сканирования?

Сканирование продолжится в фоне — оно запущено в терминале, а не в браузере. Просто откройте браузер снова на `http://localhost:8000`.

PDF попал в «На проверку» с пометкой «содержит только изображения»

Некоторые PDF-файлы не содержат текстового слоя — например, сканы документов или чертежи, сохранённые как изображение. Платформа распознаёт такие файлы и автоматически направляет их на ручную проверку вместо того, чтобы ошибочно ставить низкую оценку.

Чтобы платформа прочитала содержимое таких файлов, включите опцию **«Изображения в PDF»** в форме сканирования и запустите сканирование папки повторно.

Как очистить базу данных?

Удалите файл `project/data/index.db` и запустите сканирование заново. Все предыдущие результаты при этом удалятся.